

Report — Cosmos 3 Nano Reasoner × HATREC

Mục 1: Thông tin cơ bản

Mục	Nội dung
Tên model test	Cosmos 3 Nano Reasoner (NVIDIA), qua endpoint chính thức NVIDIA Build
Dataset test trên	HATREC — video lắp ráp công nghiệp, phân loại 7 công đoạn
Quy mô	546 video / 78 cycle / 7 lớp cân bằng (78 video mỗi lớp)
Đặc điểm video	720×1280, 30 fps, dài trung bình 3.46 s (min 1.57 s, max 7.30 s)
Độ phủ đã chạy	546/546 = 100%
Ngày test	2026-07-27 → 2026-07-28
Người test	Sơn

7 nhãn công đoạn: 0 = Assembling the spring · 1 = Placing the white plastic part · 2 = Screwing-1 · 3 = Inflating the valve · 4 = Placing the black plastic part · 5 = Screwing-2 · 6 = Fixing the cable

Mục 2: Setup

Mục	Nội dung
Chạy ở đâu	Máy local, tự động hoá trình duyệt tới NVIDIA Build
Chi phí	0 đ — free tier, không thuê server
Bản model	Cosmos 3 Nano Reasoner, endpoint chính thức, không lượng tử hoá
Zero-shot?	CÓ — hoàn toàn zero-shot. Không fine-tune, không few-shot example
Có train gì không?	KHÔNG. Không probe, không classifier, không head huấn luyện
Đầu vào	Video đầy đủ (không trích frame), upload trực tiếp lên UI
Prompt	Prompt video công nghiệp có cấu trúc, yêu cầu 9 mục bắt buộc, kết thúc bằng <code>MOST LIKELY HATREC TASK + CONFIDENCE AND LIMITATIONS</code>
Runner	<code>research/hatrec_cosmos3/run_ui.py</code>
Latency trung bình	16.49 s/video

Lưu ý về hai lần chấm điểm: lần chấm đầu (`outputs/ui_evaluation.json`) chỉ parse được 135/546 output → accuracy 18.52%. Parser sau đó được cải tiến, phục hồi được **449/546** output → các con số trong báo cáo này lấy từ lần chấm sâu (`outputs/analysis/deep_audit_summary.json`). Con số 18.52% từng lưu hành **đã lỗi thời**, không dùng nữa.

Mục 3: Kiểm tra leak

Kiểm tra	Kết quả	Trạng thái
Tên file có lộ nhãn không	Tên gốc Cycle_0_task_3.mp4 chứa nhãn. Runner copy sang tên trung tính sample_000123.mp4 trong thư mục tạm rồi mới upload, và verify tên đã upload (upload_verified: true)	 PASS
Cycle/participant trùng giữa train/test	Không áp dụng — zero-shot, không có tập train	—
Embedding similarity train↔test	Không áp dụng — model không được huấn luyện trên dữ liệu này	—
Video hỏng / trùng lặp	546/546 video hợp lệ, phân bố lớp cân bằng tuyệt đối (78 mỗi lớp)	 PASS
Nhãn có lọt vào prompt không	Không — prompt chỉ mô tả nhiệm vụ và liệt kê 7 lựa chọn	 PASS

Kết luận: Với Cosmos 3, **không có đường leak nào**. Model chưa từng thấy HATREC, tên file đã trung tính hoá và được xác minh, nhãn không xuất hiện trong prompt. Dữ liệu đủ độc lập để tin kết quả Mục 4.

⚠ Lưu ý riêng cho dataset: HATREC có các quan ngại về hiệu lực đã phát hiện khi làm việc với V-JEPA 2 (các cycle rất giống nhau về mặt thị giác, similarity 0.99). Điều đó **ảnh hưởng tới model có huấn luyện**, không ảnh hưởng tới đánh giá zero-shot này. Chi tiết ở 04_vjepa2_hatrec.md .

Mục 4: Kết quả chính

Dataset cân bằng hoàn hảo (7 lớp × 78), nên chance = 14.29%. Metric chính: **Macro-F1**.

4.1 Kết quả tổng

	Accuracy	Macro-F1	n
Cosmos 3 Nano — end-to-end (output không parse được tính là sai)	23.63% (CI 20.15–27.29)	0.2162	546
Cosmos 3 Nano — có điều kiện (chỉ tính output parse được)	28.73% (CI 24.72–32.96)	0.2394	449
Baseline majority-class	14.29%	0.0357	546
Baseline random-choice	14.29%	—	546
Chênh lệch (end-to-end vs majority)	+9.34 điểm	+0.1805 (gấp 6.1×)	

Khoảng tin cậy end-to-end [20.15%, 27.29%] **không chứa** mốc baseline 14.29% → chênh lệch có ý nghĩa thống kê.

Cận trên lạc quan nhất (giả sử toàn bộ 97 output không parse được đều đúng): **41.39%**. Kể cả trong kịch bản tốt nhất này, model vẫn sai gần 6/10 lần.

Macro precision 0.2712 · Macro recall 0.2363.

4.2 Theo từng lớp — phát hiện quan trọng nhất

Nhãn	Tên công đoạn	Support	Đúng	Precision	Recall	F1
4	Placing black plastic	78	42	0.326	0.538	0.406
1	Placing white plastic	78	19	0.543	0.244	0.336
2	Screwing-1	78	37	0.236	0.474	0.315
5	Screwing-2	78	22	0.253	0.282	0.267
6	Fixing cable	78	8	0.500	0.103	0.170
0	Assembling the spring	78	1	0.042	0.013	0.020
3	Inflating the valve	78	0	0.000	0.000	0.000

! Sụp đổ lớp (class collapse). Lớp 3 "Inflating the valve" đúng **0/78**, và trong toàn bộ 449 output parse được, model chỉ **một lần duy nhất** dự đoán lớp này. Lớp 0 "Assembling the spring" đúng 1/78.

Phân bố dự đoán (449 output parse được) so với phân bố thật (mỗi lớp phải ~14.3%):

Nhãn dự đoán	Số lần	Tỉ lệ
2 — Screwing-1	157	34.97%
4 — Placing black plastic	129	28.73%
5 — Screwing-2	87	19.38%
1 — Placing white plastic	35	7.80%
0 — Assembling the spring	24	5.35%
6 — Fixing cable	16	3.56%
3 — Inflating the valve	1	0.22%

Model dồn 83% dự đoán vào 3 lớp. Total-variation distance so với phân bố thật = 0.402.

4.3 Độ tin cậy — không hiệu chỉnh

Chỉ số	Giá trị	Ý nghĩa
ECE	0.5552	Sai lệch hiệu chỉnh cực lớn
Brier score	0.5188	
Confidence hay gặp nhất	0.9 (167 lần), 0.95 (57 lần)	Model nói "chắc 90%" trong khi đúng 24%

Model **tự tin sai một cách hệ thống**. Đây là điểm đối lập trực tiếp với yêu cầu "calibrated confidence + abstention" mà dự án đặt ra.

4.4 Tỷ lệ hoàn thành — nút thất hạ tầng

Trạng thái	Số lượng	Tỷ lệ
complete (hoàn tất bình thường)	125	22.9%
partial_timeout (bị cắt giữa chừng)	405	74.2%
timeout_no_output (không ra chữ nào)	16	2.9%
Parse được nhận	449	82.2%

Tuân thủ định dạng: đủ 9 mục = 65.93%; có tag bằng chứng = 36.26%.

77% số lần chạy bị timeout ở mức nào đó. Đây vừa là giới hạn của UI, vừa là dấu hiệu model "nghĩ" quá dài cho một video 3.5 giây.

Mục 5: Kiểm tra shortcut

HATREC là video → mục này có áp dụng.

Kiểm tra	Trạng thái	Ghi chú
Static-frame (lấy 1 frame lặp lại)	✗ CHƯA LÀM	Bắt buộc bổ sung
Temporal shuffle / đảo ngược thứ tự frame	✗ CHƯA LÀM	
Che vật thể / can thiệp nền	✗ CHƯA LÀM	

Chưa có số static-frame nên chưa kết luận được theo tiêu chí <5% / >20–30% của template.

Tuy nhiên có một chỉ báo gián tiếp đã đo được từ phân tích ngữ nghĩa nội dung sinh ra:

Chỉ số	Giá trị
Tỷ lệ bằng chứng mang tính thời gian (mean temporal evidence ratio)	0.1764
Tỷ lệ kết luận có được lập luận đỡ	0.8223
Tỷ lệ khẳng định chắc chắn nhưng không có căn cứ	0.6886
Tỷ lệ có nêu giới hạn nhận thức rõ ràng	0.8590

Chỉ **17.6%** bằng chứng model viện dẫn là về chuyển động/trình tự thời gian; hơn 82% là mô tả tĩnh (vật thể, màu sắc, bố cục bàn làm việc). Đây là **dấu hiệu cho thấy model chủ yếu đọc khung hình tĩnh**, phù hợp với việc nó nhầm lẫn nặng giữa Screwing-1 và Screwing-2 — hai công đoạn gần như không phân biệt được nếu không theo dõi trình tự thời gian.

⚠ Lưu ý về diễn giải: các chỉ số này mô tả **văn bản model sinh ra**, không phải hành vi nội tại của model. Muốn kết luận chắc chắn vẫn phải chạy static-frame control.

Mục 6: Ví dụ lỗi cụ thể

Tất cả lấy từ 546 video test (không có tập train).

Lỗi 1 — Cycle_0/Cycle_0_task_3

- **Đáp án thật:** 3 — Inflating the valve
- **Model đoán:** 0 — Assembling the spring
- **Confidence model tự khai:** 0.9 | runtime: thinking_too_long, 16.42 s
- **Loại lỗi: Model hallucinate + sụp đổ lớp.** Model tự tin 90% vào một nhãn hoàn toàn khác. Kết hợp với việc lớp 3 chỉ được dự đoán 1/449 lần trên toàn bộ dataset → model **không có biểu diễn nào cho công đoạn bơm van**, nó thay bằng công đoạn quen thuộc hơn.

Lỗi 2 — Cycle_10/Cycle_10_task_3

- **Đáp án thật:** 3 — Inflating the valve | **Model đoán:** 1 — Placing white plastic
- **Confidence:** 0.6 | runtime: normal (14.29 s — chạy trọn vẹn, không timeout)
- **Loại lỗi: Model hallucinate.** Đây là ca chạy *bình thường*, không bị cắt, model có đủ thời gian và vẫn sai. Chứng minh lỗi ở lớp 3 **không phải do timeout** mà do bản thân năng lực nhận dạng.

Lỗi 3 — Cycle_0/Cycle_0_task_0

- **Đáp án thật:** 0 — Assembling the spring | **Model đoán:** 2 — Screwing-1
- **Confidence:** 0.9
- **Loại lỗi: Nhầm lẫn giữa 2 nhãn quá giống nhau + thiên lệch về lớp trội.** Lắp lò xo và vặn vít đều là thao tác tay nhỏ trên cùng cụm chi tiết. Screwing-1 là nhãn model dự đoán nhiều nhất (34.97%) → model rơi về lớp mặc định khi không chắc.

Lỗi 4 — Cycle_1/Cycle_1_task_6

- **Đáp án thật:** 6 — Fixing cable | **Model đoán:** không có output (0 ký tự)
- **Trạng thái:** timeout_no_output
- **Loại lỗi: Thiếu thông tin đầu ra — giới hạn hạ tầng.** Model không trả lời gì. Trong chấm end-to-end ca này tính là sai. Có 16 ca như vậy.

Lỗi 5 — Cycle_0/Cycle_0_task_5

- **Đáp án thật:** 5 — Screwing-2 | **Model đoán:** bị cắt giữa chừng sau 4,882 ký tự
- **Trạng thái:** partial_timeout
- **Loại lỗi: Thiếu thông tin đầu vào/đầu ra — model "nghĩ" quá dài.** Model viết gần 5,000 ký tự phân tích cho một video 5.9 giây rồi bị cắt trước khi kết luận. Có 405 ca partial_timeout (74.2%).

Lỗi 6 — Cycle_11/Cycle_11_task_0

- **Đáp án thật:** 0 — Assembling the spring | **Model đoán:** 4 — Placing black plastic
- **Confidence:** 0.6
- **Loại lỗi: Nhầm lẫn giữa 2 nhãn quá giống nhau.** Cả hai đều là thao tác đặt/lắp chi tiết nhỏ; phân biệt được phải nhìn *vật thể nào* đang cầm — chi tiết dễ mất ở độ phân giải sau nén.

Ma trận nhầm lẫn — các cặp nhầm nhiều nhất

Thật → Đoán	Số lần
0 (Assembling spring) → 1 (White plastic)	21
5 (Screwing-2) → 1 (White plastic)	16
5 (Screwing-2) → 2 (Screwing-1)	14
2 (Screwing-1) → 1 (White plastic)	13
0 (Assembling spring) → 2 (Screwing-1)	10

Cặp Screwing-2 → Screwing-1 (14 lần) là bằng chứng trực tiếp: hai công đoạn chỉ khác nhau ở **vị trí trong trình tự thời gian**, và model không phân biệt được.

Mục 7: Kết luận cuối cùng

Dataset: HATREC (546 video, phân loại 7 công đoạn)

- ☒ **Model này THẮNG RÕ RÀNG so với baseline đơn giản** — Macro-F1 0.2162 vs 0.0357 (gấp 6.1×); accuracy 23.63% vs 14.29%; CI 95% [20.15%, 27.29%] không chứa mốc baseline.
- ☐ Model này NGANG BẰNG baseline đơn giản
- ☐ Model này THUA baseline đơn giản

⚠️ "Thắng baseline" ở đây KHÔNG có nghĩa là "dùng được". Model sai 76% số lần, hỏng hoàn toàn 2/7 lớp, tự tin 90% khi đoán sai, và 77% số lần chạy bị timeout. Về mặt vận hành đây là **không khả dụng**. Ô đánh dấu ở trên chỉ phản ánh việc model có tín hiệu thị giác thật vượt trên mức đoán mò — không phải khuyến nghị triển khai.

Mục 8: Lưu ý / giới hạn

Mẫu test có đủ lớn không?

Có, ở mức tổng: 546 video, phủ 100% dataset, các lớp cân bằng tuyệt đối. Ở mức từng lớp thì 78 mẫu/lớp là chấp nhận được nhưng khoảng tin cậy per-class khá rộng. Điểm yếu thật sự không phải cỡ mẫu mà là **chỉ 82.2% output parse được**.

Có phát hiện leak không? Kết quả Mục 4 có đáng tin?

Không phát hiện leak. Tên file đã trung tính hoá và verify, nhãn không lọt vào prompt, model chưa từng huấn luyện trên HATREC. Kết quả Mục 4 **đáng tin** trong phạm vi đã đo. Cảnh báo duy nhất: 17.8% output không parse được có thể không phân bố ngẫu nhiên (lớp 5 Screwing-2 có tới 6 ca timeout so với 1 ca của lớp 0), nên con số per-class có thể lệch nhẹ.

Có điều gì chưa kiểm tra mà làm thêm sẽ chắc chắn hơn?

- Static-frame control** — bắt buộc, và là việc còn thiếu quan trọng nhất. Với temporal evidence ratio chỉ 0.176, khả năng cao model không dùng chuyển động. Cần biết chắc trước khi kết luận Cosmos "hiểu video".

- 2. **Temporal shuffle control** — đảo thứ tự frame. Nếu điểm không đổi → xác nhận model bỏ qua thông tin thời gian.
- 3. **Điều tra lớp 3 (Inflating the valve)** — 0/78 và chỉ được dự đoán 1 lần. Cần kiểm tra xem đây là do prompt mô tả nhãn không rõ, hay do model thật sự không nhận ra công đoạn này. Sửa mô tả nhãn trong prompt rồi chạy lại 78 video của lớp này là thí nghiệm rẻ.
- 4. **Giảm timeout** — 74.2% partial_timeout đang bóp méo kết quả. Nên thêm chỉ thị giới hạn độ dài suy luận, hoặc tăng timeout, rồi chạy lại.
- 5. **Chưa so với model video chuyên dụng nào khác trên cùng split** ngoài V-JEPA 2 (vốn có setup khác hẳn — có huấn luyện probe). Chưa có so sánh zero-shot ↔ zero-shot công bằng.
- 6. **Chưa có human baseline** — video chỉ 3.5 giây, cần biết người thường phân biệt được 7 công đoạn này chính xác đến đâu.

Nguồn dữ liệu và mã nguồn

Loại	Đường dẫn
Kết quả từng video	research/hatrec_cosmos3/outputs/analysis/hatrec_cosmos3_per_video.csv
Tổng hợp chấm sâu	.../outputs/analysis/deep_audit_summary.json
Chỉ số per-class	.../outputs/analysis/deep_per_class_metrics.csv
Phân loại lỗi	.../outputs/analysis/deep_error_taxonomy.csv
Phân tích ngữ nghĩa	.../outputs/analysis/semantic_content_summary.json , semantic_cue_confusion.csv
Báo cáo thô từng video	.../outputs/ui_reports/Cycle_*/ (78 thư mục)
Log chạy	.../outputs/ui_run_546.log
Runner	research/hatrec_cosmos3/run_ui.py
Audit dataset	.../outputs/dataset_audit.json
Notebook phân tích	research/hatrec_cosmos3/HATRec_Cosmos3_Insight_Analysis.ipynb

Hình nên gắn kèm khi trình bày:

outputs/analysis/deep_confusion_matrices.png , outputs/analysis/per_class_prf1.png ,
outputs/analysis/confidence_calibration.png , outputs/analysis/completion_status.png .