

Report — Qwen2-VL-2B × MMAD

Mục 1: Thông tin cơ bản

Mục	Nội dung
Tên model test	Qwen2-VL-2B-Instruct (Qwen/Qwen2-VL-2B-Instruct)
Dataset test trên	MMAD (ICLR 2025) — industrial visual anomaly benchmark
Quy mô	39,670 câu MCQ / 8,366 ảnh / 38 category / 4 nguồn / 7 task
Ngày test	2026-07-29 → 2026-07-30
Người test	Sơn
Manifest SHA-256	ff6bf9547135bb9b58dcafcfbaf73e0cfbf804edea0b6dee57fa4dbbf5fb5d6

Mục 2: Setup

Mục	Nội dung
Chạy ở đâu	Kaggle, GPU T4 (free tier)
Chi phí	0 đ — không thuê server
Bản model	Qwen2-VL-2B-Instruct, 2B params
Backend	Transformers FP16, attention SDPA, batch = 4, có OOM fallback
Zero-shot?	CÓ — hoàn toàn zero-shot. Không fine-tune, không probe, không few-shot example nào trong prompt
Có train gì không?	KHÔNG. Không XGBoost, không linear probe, không head nào được huấn luyện
Sinh output	Deterministic (greedy). Parser chỉ chấp nhận đúng một chữ cái A–D không nhập nhầm
Notebook	research/mmad_model_benchmark/models/qwen2_vl/Qwen2VL_2B_MMAD_Full.ipynb
Resume	Checkpoint JSONL theo <code>sample_id</code> ổn định, không dùng vị trí

Ghi chú: đây là setting zero-shot theo protocol nội bộ, **không phải** bản tái hiện setting 1-shot và domain-knowledge của paper MMAD gốc. Vì vậy không so trực tiếp được với leaderboard chính thức.

Mục 3: Kiểm tra leak

Vì đây là zero-shot thuần, **không tồn tại tập train của mình** → không có khái niệm cycle/participant trùng giữa train/test, và embedding-similarity train↔test không áp dụng. Các kiểm tra thay thế đã làm:

Kiểm tra	Kết quả	Trạng thái
Tên file query có lỗi nhãn không	Đổi hết thành <code>sample_XXXX</code> trước khi đưa vào prompt	✅ PASS
Nhãn source / class / defect có xuất hiện trong prompt không	Không — chỉ có ảnh + câu hỏi + 4 lựa chọn	✅ PASS
Annotation gốc có bị chèn vào prompt không	Không — chỉ dùng để chấm điểm	✅ PASS
Parser có "đoán hột" model không	Không — chỉ nhận A–D rõ ràng, còn lại tính <code>parse_failure</code>	✅ PASS
Model có thấy MMAD lúc pretrain không	CHƯA KIỂM TRA ĐƯỢC	⚠️ REVIEW

Kết luận: Ở mức protocol, dữ liệu đủ độc lập — model không nhận được manh mối nào ngoài pixel và câu hỏi. Rủi ro còn lại là **nhiểm bẩn từ pretraining**: MMAD là dataset public trên HuggingFace từ ICLR 2025, Qwen2-VL có thể đã gặp ảnh MVTec-AD/VisA trong dữ liệu huấn luyện. Không có cách kiểm chứng từ phía mình. Rủi ro này áp dụng như nhau cho mọi model open-source được so sánh, nên **không làm sai lệch phép so sánh giữa các model**, chỉ làm con số tuyệt đối lạc quan hơn thực tế.

Mục 4: Kết quả chính

4.1 Toàn bộ MMAD

MMAD là MCQ 2–4 lựa chọn, phân bố đáp án hơi lệch (A 30.4% / B 30.1% / C 20.3% / D 19.2%). Metric chính báo cáo là **Macro-F1 trên nhãn đáp án** kèm micro accuracy theo protocol công bố của MMAD.

	Micro accuracy	Macro-F1	n
Qwen2-VL-2B	64.73% (CI 95% 64.26–65.20)	0.6499	39,669
Baseline majority-letter (luôn trả lời A)	30.38%	0.1165	39,669
Baseline random-choice (kỳ vọng)	30.21%	—	39,669
Chênh lệch vs majority	+34.35 điểm (gấp 2.13×)	+0.5334	

Baseline được tính bằng code riêng trên **đúng 39,669 record model đã trả lời**, không mượn từ nguồn khác.

4.2 Theo nguồn dữ liệu

Nguồn	n	Accuracy	CI 95%
MVTec-AD	8,336	75.25%	74.31–76.17
GoodsAD	13,088	64.23%	63.40–65.04
VisA	10,621	63.93%	63.01–64.84
MVTec-LOCO	7,624	55.22%	54.10–56.33

Chênh 20 điểm giữa nguồn dễ nhất và khó nhất. **Hệ quả quan trọng cho việc so sánh:** bất kỳ model nào chỉ chạy trên MVTec-AD sẽ có con số cao giả tạo. Xem `02_cosmos3_nano_mmad.md`.

4.3 Theo task

Task	n	Accuracy
Object Classification	3,155	93.82%
Object Analysis	9,160	78.30%
Defect Analysis	4,782	72.90%
Defect Description	4,710	63.74%
Anomaly Detection	8,297	58.31%
Defect Localization	4,877	46.73%
Defect Classification	4,688	41.42%

4.4 Anomaly Detection — subtask quan trọng nhất về mặt vận hành

Đây là dữ liệu mất cân bằng (60.83% câu là "có lỗi"), nên **không dùng accuracy**:

	Precision	Recall	F1	Miss rate	Overkill rate
Qwen2-VL-2B	0.7428	0.4807	0.5837	51.93%	25.85%
Baseline "luôn nói có lỗi"	0.6083	1.0000	0.7564	0%	100%
Chênh lệch	+0.1345	-0.5193	-0.1727		

⚠️ **Trên riêng subtask Anomaly Detection, Qwen2-VL-2B THUA baseline ngu.** F1 0.584 so với 0.756; accuracy 58.31% so với 60.83%. Model bỏ sót hơn một nửa số ca lỗi thật.

Chi tiết theo nguồn (mức bỏ sót rất khác nhau):

Nguồn	Precision	Recall	F1	Miss rate
MVTec-AD	0.850	0.834	0.841	16.6%
VisA	0.650	0.689	0.669	31.1%
GoodsAD	0.733	0.254	0.377	74.6%
MVTec-LOCO	0.722	0.167	0.272	83.3%

4.5 Độ trễ

Median 0.687 s/câu, p95 0.773 s, mean 0.691 s. Toàn bộ 39,670 câu chạy trong khoảng 7.6 giờ GPU T4.

Mục 5: Kiểm tra shortcut

MMAD là **ảnh tĩnh đơn**, không phải video → **test static-frame không áp dụng**.

Phép kiểm tương đương cho ảnh tĩnh là **blind-image control** (thay ảnh thật bằng ảnh nhiễu hoặc ảnh không liên quan, giữ nguyên câu hỏi). Nếu điểm không giảm → model đang trả lời bằng kiến thức ngôn ngữ chứ không nhìn ảnh.

Kiểm tra	Trạng thái
Blind-image control	✗ CHƯA LÀM
Answer-position bias	✓ Đã đo

Answer-position bias đã đo được:

Đáp án	Tỉ lệ trong ground truth	Tỉ lệ model chọn	Lệch
A	30.38%	31.10%	+0.72%
B	30.11%	27.02%	-3.09%
C	20.31%	19.57%	-0.74%
D	19.20%	22.30%	+3.10%

Lệch tối đa 3.1 điểm — có thiên lệch vị trí nhẹ nghiêng về D, nhưng chưa đủ lớn để giải thích kết quả. Không phải shortcut nghiêm trọng.

Kết luận mục 5: chưa đủ căn cứ khẳng định model thật sự "nhìn" ảnh. Blind-image control là việc bắt buộc phải bổ sung — với model 2B và độ chênh giữa các task rất lớn (93.8% vs 41.4%), khả năng một phần điểm đến từ prior ngôn ngữ là có thật.

Mục 6: Ví dụ lỗi cụ thể

Toàn bộ lấy từ tập test đầy đủ (không có tập train). Mỗi ca ghi rõ model đoán gì / đáp án thật / phân loại nguyên nhân.

Lỗi 1 — `mmad_full_00064` (MVTec-AD / bottle / Anomaly Detection)

- Câu hỏi:** "Is there any defect in the object?" — A) No. B) Yes.
- Đáp án thật:** A — "No." (ảnh này là hàng bình thường)
- Model đoán:** B — "Yes."
- Loại lỗi: Lý do khác — thiên lệch trả lời.** Model báo động giả trên hàng tốt. Khớp với overkill_rate 25.85% toàn cục. Ca `mmad_full_00065` cùng category lặp lại y hệt.

Lỗi 2 — `mmad_full_08311` (MVTec-AD / bottle / Defect Classification)

- Câu hỏi:** "What is the type of the defect?" — A) Breakage. B) Stain. C) Discoloration. D) Crack.
- Đáp án thật:** A — "Breakage."
- Model đoán:** D — "Crack."
- Loại lỗi: Nhầm lẫn giữa 2 nhãn quá giống nhau.** "Breakage" (vỡ hẵn) và "Crack" (nứt) khác nhau ở mức độ, đòi hỏi phân biệt độ sâu/mức phá huỷ. Đây là mẫu lỗi chi phối task Defect Classification (41.42% — task yếu nhất).

Lỗi 3 — `mmad_full_12991` (MVTec-AD / bottle / Defect Localization)

- Câu hỏi:** "Where is the defect?" — A) Bottom center. B) Left side. C) Right side. D) Top center.
- Đáp án thật:** A — "Bottom center of the image."
- Model đoán:** D — "Top center of the image."

- Loại lỗi: Lý do khác — yếu định vị không gian. Model chọn đúng trục (center) nhưng ngược chiều dọc hoàn toàn. Đây không phải nhầm lẫn nhãn giống nhau mà là hỏng khả năng grounding toạ độ — đúng với Defect Localization 46.73%.

Lỗi 4 — `mmad_full_30520` (MVTec-AD / bottle / Object Analysis)

- Câu hỏi: "Where is the location of the object's opening?" — A) Bottom. B) Side. C) Top. D) Closed.
- Đáp án thật: C — "At the top of the object."
- Model đoán: A — "At the bottom of the object."
- Loại lỗi: Lý do khác — yếu định vị không gian. Cùng dạng lỗi trên/dưới với Lỗi 3, nhưng ở câu hỏi về vật thể bình thường chứ không phải về lỗi. Xác nhận đây là điểm yếu hệ thống của model, không phải do defect khó nhìn.

Lỗi 5 — `mmad_full_27502` (MVTec-AD / grid / Object Classification)

- Câu hỏi: "What kind of product is in the image?" — A) Wallpaper. B) Plastic sheeting. C) Ceramic tile. D) Textured fabric.
- Đáp án thật: D — "Textured fabric."
- Model đoán: B — "Plastic sheeting."
- Loại lỗi: Nhiều/mất chi tiết do xử lý. Phân biệt vải dệt với tấm nhựa phụ thuộc vào kết cấu sợi ở tần số không gian cao — thứ dễ mất nhất khi resize ảnh về độ phân giải đầu vào của model.

Lỗi 6 — `mmad_full_22618` (MVTec-AD / bottle / Defect Analysis)

- Câu hỏi: "What may be the effect of the defect?" — A) Change in liquid flavor or contamination. B) Unsellable. C) Affect ability to hold liquid. D) Leaking contents.
- Đáp án thật: A — "It could cause a change in liquid flavor or contamination."
- Model đoán: D — "It could lead to leaking contents."
- Loại lỗi: Nhầm lẫn giữa 2 nhãn quá giống nhau. Cả 4 lựa chọn đều là hệ quả hợp lý của một chai bị lỗi; muốn chọn đúng phải biết loại lỗi cụ thể trên ảnh. Model suy luận hệ quả chung chung thay vì căn cứ vào bằng chứng thị giác.

Phân bố lỗi theo category (Pareto — 5 category chiếm 32.3% tổng lỗi)

Nguồn	Category	Số lỗi	% tổng lỗi
GoodsAD	drink_bottle	1,248	8.92%
GoodsAD	food_bottle	876	6.26%
GoodsAD	food_package	824	5.89%
MVTec-LOCO	screw_bag	814	5.82%
MVTec-LOCO	juice_bottle	758	5.42%

Mục 7: Kết luận cuối cùng

Dataset: MMAD (toàn bộ 39,670 câu)

- ☒ **Model này THẮNG RÕ RÀNG so với baseline đơn giản** — 64.73% vs 30.38% majority-letter, chênh +34.35 điểm, khoảng tin cậy không chồng lấn.
- ☐ Model này NGANG BẰNG baseline đơn giản
- ☐ Model này THUA baseline đơn giản

Kết luận phụ bắt buộc phải ghi kèm — subtask Anomaly Detection (n = 8,297):

- ☐ THẮNG RÕ RÀNG
- ☐ NGANG BẰNG
- ☒ **THUA baseline đơn giản** — F1 0.584 vs 0.756 của baseline "luôn nói có lỗi"; miss rate 51.93%.

Hai kết luận này không mâu thuẫn: Qwen2-VL-2B là **model mô tả và nhận dạng vật thể tốt**, nhưng **không dùng được làm công phát hiện bất thường** vì bỏ sót quá nửa số ca lỗi. Nếu mục tiêu công ty là B3 (anomaly & fault localization), con số 64.73% không phản ánh đúng năng lực thực tế.

Mục 8: Lưu ý / giới hạn

Mẫu test có đủ lớn không?

Có. 39,669 record parse-valid, CI 95% chỉ ± 0.47 điểm. Đây là bộ đầy đủ, không phải subset. Mọi kết luận ở mức toàn dataset đều vững về mặt thống kê.

Có phát hiện leak không? Kết quả Mục 4 có đáng tin?

Không phát hiện leak ở mức protocol — tên file đã trung tính, nhãn không lọt vào prompt, parser không đoán hộ. Kết quả Mục 4 đáng tin ở mức so sánh tương đối giữa các model chạy cùng manifest. Con số tuyệt đối có thể lạc quan do khả năng nhiễm bẩn pretraining, không kiểm chứng được.

Có điều gì chưa kiểm tra mà làm thêm sẽ chắc chắn hơn?

1. **Blind-image control** — bắt buộc. Không có nó thì chưa chứng minh được model thật sự dùng ảnh. Chi phí thấp: chạy lại một mẫu ~500 câu với ảnh bị xáo trộn.
 2. **Chưa lưu probability/logits** — nên không claim được gì về calibration (ECE) hay khả năng abstain. Cần bật ở lần chạy sau, đây là yêu cầu của Cosmos-style confidence.
 3. **Chưa chạy setting 1-shot và domain-knowledge** của MMAD gốc → không đối chiếu được với leaderboard chính thức và với mốc GPT-4o ~74.9%.
 4. **Chưa phân tích ảnh hưởng độ phân giải** — nghi ngờ ở Lỗi 5 (mất kết cấu do resize) chưa được kiểm chứng bằng thí nghiệm đổi độ phân giải đầu vào.
 5. **Chưa có human baseline nội bộ** trên cùng subset để biết trần thực tế của bộ dữ liệu này.
-

Nguồn dữ liệu và mã nguồn

Loại	Đường dẫn
Prediction thô	research/mmad_model_benchmark/models/qwen2_vl/qwen2_vl_mmad_full_results/predictions.jsonl
Bảng chấm điểm	.../qwen2_vl_mmad_full_results/predictions_scored.csv
Metrics	.../qwen2_vl_mmad_full_results/metrics.json
Phân tích sâu + hình	.../qwen2_vl_mmad_full_results/deep_analysis/
Hình tổng quan	.../qwen2_vl_mmad_full_results/full_mmad_analysis.png
Notebook	research/mmad_model_benchmark/models/qwen2_vl/Qwen2VL_2B_MMAD_Full.ipynb
Repo public	https://github.com/ahsown/mini-world-model

Hình nên gắn kèm khi trình bày:

deep_analysis/02_task_source_accuracy_ci.png , deep_analysis/05_anomaly_by_source.png , deep_analysis/07_error_pareto_latency.png .